

Optimisation Non linéaire

Par

Professeur Abdellatif El Afia

Chapitre 3

Optimisation sans contrainte

- Fonction à plusieurs variables
 - Méthodes itératives de résolution
 - Recherche linéaire approchée.

Optimisation sans contrainte : Fonction à plusieurs variables

- $f: \mathbb{R}^n \rightarrow \mathbb{R} \Rightarrow x = (x_1, \dots, x_n)^T$
- $\nabla f(x)$ vecteur d'ordre $n \rightarrow \nabla^2 f(x)$ matrice d'ordre $n \times n$
- $x^* = \underset{x \in \mathbb{R}^n}{\operatorname{argmin}} f(x)$
- $\{x^k\}$ tel que
 - Calcul de d^k
 - $x^{k+1} = x^k + \alpha_k d^k \Rightarrow \alpha_k = \underset{\alpha > 0}{\operatorname{argmin}} \varphi(\alpha)$ Recherche linéaire: $\varphi(\alpha) = f(x^k + \alpha d^k)$ (Chapitre 2)
- Objectif 1: Type des d^k
 - Gradient $\Leftrightarrow d^k = -\nabla f(x^k)$
 - Gradient Conjugué $\Leftrightarrow x^{k+1} = x^k + \alpha_k d^k$ avec $(d^i)^T Q d^j = 0 \quad \forall i \neq j \Leftrightarrow x^* = \sum_{k=0}^{n-1} \alpha_k d^k$
 - Newton $\Leftrightarrow d^k = -(\nabla^2 f(x))^{-1} \nabla f(x^k)$
 - Quasi-Newton $\Leftrightarrow d^k = -H_k \nabla f(x^k)$
- Objectif 2: la recherche linéaire approchée

Méthodes itératives de résolution


- **Méthode de gradient**
- **Gradient conjugué**
- **Algorithme de Newton**
- **Algorithme Quasi-Newton**

Méthode de gradient

1. **Algorithme**
2. **Exemple**
3. **Convergence**
4. **Déplacement**

Méthode de gradient: Algorithme $d^k = -\nabla f(x^k)$

- Entrée :
 - x^0 : Réel (point initial)
 - δ : Réel (la tolérance)
 - f : Fonction ($f: \mathbb{R}^n \rightarrow \mathbb{R}^1$ et $f \in C^1$)
- Sortie :
 - x^* : Réel (point de sortie)
- Début : $k = 0$
- WHILE($\|\nabla f(x^k)\| > \delta$ or $\|x^k - x^{k-1}\| > \delta$) {
 - Déterminer α_k tel que $\alpha_k = \underset{\alpha \geq 0}{\operatorname{argmin}} \{f(x^k - \alpha \nabla f(x^k))\}$
 - $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$
 - $k = k + 1$}
- $x^* = x^k$
- RETURN x^*
- Fin



Méthode de gradient: Exemple

$$f = \frac{1}{2}(x_1^2 + x_2^2) \rightarrow \nabla f(x_1, x_2) = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \rightarrow \nabla^2 f(x_1, x_2) = I$$

Itération 1 :

Etape 0 : $k = 0$, $x^0 = \begin{pmatrix} x_1^0 \\ x_2^0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$, $\delta = 10^{-2}$

Etape 1 : $\nabla f(x^0) = \nabla f(x_1^0, x_2^0) = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \rightarrow \|\nabla f(x^0)\| = \sqrt{4 + 1} = \sqrt{5} > 10^{-2}$

Etape 2 : α_0 solution optimal de $\min_{\alpha \geq 0} f(x^0 - \alpha \nabla f(x^0))$

- $\varphi(\alpha) = f(x^0 - \alpha \nabla f(x^0)) = \frac{1}{2}((2 - 2\alpha)^2 + (1 - \alpha)^2) \Rightarrow \varphi'(\alpha) = -3 + 3\alpha = 0 \Rightarrow \alpha_0 = 1$

- $x^1 = x^0 - \alpha_0 \nabla f(x^0) = \begin{pmatrix} x_1^0 - 2\alpha_0 \\ x_2^0 - \alpha_0 \end{pmatrix} = \begin{pmatrix} 2 - 2 \times 1 \\ 1 - 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

Itération 2 :

Etape 1: $\nabla f(x^1) = \nabla f(x_1^1, x_2^1) = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \|\nabla f(x^1)\| = 0 < 10^{-2} \rightarrow \text{arrête}$

$$x^* = \begin{pmatrix} x_1^* \\ x_2^* \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Méthode de gradient: Convergence

Lemme : Soit $f \in C^1$. Tout point limite x^* d'une sous-suite convergente de la suite générée par la méthode du gradient est tel que $\nabla f(x^*) = 0$.

Théorème :

Si $f \in C^1$ et tel que $\lim_{\|x\| \rightarrow +\infty} f(x) = +\infty$ alors, pour tout point de départ x_0 , la méthode de la plus fort pente converge vers un point stationnaire de f .

Théorème :

Soit une fonction $f: \mathbb{R}^n \rightarrow \mathbb{R}$ convexe et différentiable, tel que :

$$\forall x, y \in \mathbb{R}^n, \quad \text{on a } \|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$$

(i.e. ∇f est L -Lipchitzienne avec constante $L > 0$)

Alors l'algorithme de gradient descendant avec **un pas fixe** $\alpha \leq 1/L$ satisfait à la relation

$$\text{suivante : } \|f(x^k) - f(x^*)\| \leq \frac{\|x^0 - x^*\|^2}{2\alpha_k}$$

- **L'ordre de convergence** de la méthode du gradient est linéaire.
- Ainsi pour arriver à $\|f(x^k) - f(x^*)\| \leq \varepsilon$, on a besoin de $O(1/\varepsilon)$ itérations

Méthode de gradient: Convergence

Preuve de lemme:

Considérons la sous-suite $\{x^{k_j}\}$ de $\{x^k\}$ telle que $\{x^{k_j}\} \rightarrow x^*$

Par conséquent, se référant aux suites

- $\{x^k\} = \{\dots, x^{k_j}, x^{k_j+1}, \dots, x^{k_j+\tau}, \dots\}$
- $\{x^{k_j}\} = \{\dots, x^{k_j}, \dots, x^{k_{j+1}}, \dots\}$ où $x^{k_{j+1}} = x^{k_j+\tau}$.

Ainsi, se référant à la suite $\{x^k\}$

- $f(x^{k_{j+1}}) = f(x^{k_j+\tau}) \leq \dots \leq f(x^{k_j+1})$
- $f(x^{k_j+1}) = \min_{\alpha \geq 0} \left\{ f\left(x^{k_j} - \alpha \nabla f(x^{k_j})\right) \right\}$

Donc

- $f(x^{k_{j+1}}) \leq f\left(x^{k_j} - \alpha \nabla f(x^{k_j})\right) \quad \forall \alpha \geq 0$
- $f(x^{k_{j+1}}) \leq f(x^{k_j+1}) \quad (\text{puisque } k_{j+1} \geq k_j + 1)$
- $f(x^{k_j+1}) = \min_{\alpha \geq 0} \left\{ f\left(x^{k_j} - \alpha \nabla f(x^{k_j})\right) \right\},$

Ainsi $f(x^{k_{j+1}}) \leq f\left(x^{k_j} - \alpha \nabla f(x^{k_j})\right) \quad \forall \alpha \geq 0$

Méthode de gradient: Convergence

Puisque $f \in C^1$, f est continue sur \mathbb{R}^n et $\lim_{j \rightarrow \infty} f(x^{k_{j+1}}) = f(x^*)$

$$\lim_{j \rightarrow \infty} \left[f \left(x^{k_j} - \alpha \nabla f(x^{k_j}) \right) \right] = f(x^* - \alpha \nabla f(x^*)) \quad \forall \alpha \geq 0$$

Donc

$$f(x^*) \leq f(x^* - \alpha \nabla f(x^*)) \quad \forall \alpha \geq 0 \quad (3.2)$$

Par conséquent $\nabla f(x^*) = 0$ car autrement si $\nabla f(x^*) \neq 0$, alors $-\nabla f(x^*)$ **est une direction de descente** et se référant au lemme 3.2 nous obtenons une contradiction à la relation (3.2)

Remarque: Au début de son application, la méthode permet de faire diminuer la valeur de la fonction économique relativement rapidement, mais son efficacité à ce chapitre diminue au cours des itérations.

Méthode de gradient: Déplacement en zigzag

Le lemme suivant montre que la méthode de descente se déplace en zigzag puisque les directions utilisées à deux itérations successives sont à angle droit.

Lemme:

Si $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$ où α_k est tel que $f(x^k - \alpha_k \nabla f(x^k)) = \min_{\alpha \geq 0} \{f(x^k - \alpha \nabla f(x^k))\}$

Alors $\nabla f(x^{k+1})^T \nabla f(x^k) = 0$

Preuve

Si $\nabla f(x^k) = 0$ alors la preuve est complétée

Si $\nabla f(x^k) \neq 0$, considérons la fonction $\varphi : \mathbb{R}^+ \rightarrow \mathbb{R}$ $\varphi(\alpha) = f(x^k - \alpha \nabla f(x^k))$

Par dérivation en chaine,

$$\varphi'(\alpha) = -\nabla f(x^k)^T \nabla f(x^k - \alpha \nabla f(x^k))$$

Puisque α_k est un minimum local de $\varphi(\alpha)$, $\varphi'(\alpha_k) = 0$

Et alors

$$0 = \varphi'(\alpha_k) = -\nabla f(x^k)^T \nabla f(x^k - \alpha_k \nabla f(x^k)) = -\nabla f(x^k)^T \nabla f(x^{k+1})$$

Méthode de gradient: Déplacement en zigzag

Remarque:

La méthode du gradient est la méthode **la plus rapide marginalement** (« steepest descent method »)

$$\nabla f(x)^T d = \|\nabla f(x)\| \|d\| \cos(\theta)$$


où θ est l'angle entre d et $\nabla f(x)$. ainsi, parmi les directions d de norme 1 ($\|d\| = 1$) ; celle minimisant $\nabla f(x)^T d$ a un angle de 180° car $\cos(180^\circ) = -1$.

Ainsi, cette direction d correspond à

$$d = -\frac{\nabla f(x)}{\|\nabla f(x)\|}$$

- Si $\nabla f(x)^T d < 0$ alors $\cos(\theta) < 0$
- $\Rightarrow \theta \in \left] \frac{\pi}{2} + 2k\pi, \frac{3\pi}{2} + 2k\pi \right[$
- ($\|d\| = 1$)

$$d = -\nabla f(x)$$



Méthode de gradient: Cas quadratique $Q = Q^T$, $d^k \neq 0$

Soit Q est supposée définie positive. $f: \mathbb{R}^n \rightarrow \mathbb{R} \in \mathcal{C}^2$

$$f(x) = \frac{1}{2} x^T Q x - b^T x \Rightarrow \nabla f(x) = Qx - b \Rightarrow \nabla^2 f(x) = Q$$

La suite générée par la méthode du gradient est donnée par

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k) = x^k + \alpha_k d^k$$

Dans ce cas précis, on peut déterminer explicitement α_k . En effet :

$$\begin{aligned} \nabla f(x^{k+1})^T \nabla f(x^k) &= -(Qx^{k+1} - b)^T d^k \\ &= -(Q(x^k + \alpha_k d^k) - b)^T d^k \\ &= -(Qx^k - b + \alpha_k Qd^k)^T d^k \\ &= -(\nabla f(x^k) + \alpha_k Qd^k)^T d^k \\ &= -(-d_k + \alpha_k Qd^k)^T d^k \\ &= -(-d^k)^T d_k - (\alpha_k Qd^k)^T d^k \\ &= (d^k)^T d_k - \alpha_k (d^k)^T Q d^k = 0 \Rightarrow \alpha_k = \frac{(d^k)^T d^k}{(d^k)^T Q d^k} > 0 \end{aligned}$$

Méthode de gradient: Cas quadratique $Q = Q^T$, $d^k \neq 0$

Vitesse de convergence

Pour faciliter l'étude de ce vitesse de convergence on va définir la norme associée à la matrice

$$Q \text{ par } \|x\|_Q = \sqrt{x^T Q x}$$

Et on introduit la fonction utilitaire $E(x) = \frac{1}{2}(x - x^*)^T Q (x - x^*) = \frac{1}{2} \|x - x^*\|_Q^2$

Où x^* est l'unique minimum de f c.à.d. $Qx^* = b$. Alors $E(x) = f(x) + \frac{1}{2} x^{*T} Q x^*$

On remarque que E et f ne diffèrent que par une constante. Ainsi $\min_{x \in \mathbb{R}^n} f(x) \Leftrightarrow \min_{x \in \mathbb{R}^n} E(x)$

Q étant définie positive alors toutes ses valeurs propres sont strictement positive.

Si l'on désigne par $\lambda_n > \lambda_1 > 0$ la plus petite et la plus grande valeur propre de Q alors on a

théorème suivant : $\beta = \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 < 1$

Théorème :

Pour tout point de départ x^0 ; la méthode du gradient converge vers l'unique minimum x^* de f

et à chaque itération k , on a $E(x^{k+1}) \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 E(x^k)$

Méthode de gradient: Cas quadratique $Q = Q^T$, $d^k \neq 0$

Remarques

- la plus petite et la plus grande valeur propre de Q apparaissent dans le résultat car elles sont une indication du degré ‘d’aplatissement’ des courbes de niveau de f
- **si $\lambda_1 = \lambda_n$ alors ces courbe sont sphériques et la méthode du gradient converge en une seule itération quel que soit le point de départ**
- le théorème dit que la méthode du gradient converge linéairement avec un rapport de convergence $\beta < 1$
- En posant $r = \frac{\lambda_n}{\lambda_1}$ on aura :

$$\left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 = \left(\frac{r - 1}{r + 1} \right)^2$$

- r est appelé **la condition number** de Q
- Ainsi, **plus r est grand et plus la convergence est lente**, en faisant un changement de variable, il est possible d’améliorer cette vitesse.

Gradient Conjugué

- 1. Méthode fondamentale des directions conjuguées**
- 2. Principe**
- 3. Algorithme**
- 4. Exemple**
- 5. convergence**

Gradient Conjugué: Méthode fondamentale des directions conjuguées

Type de méthodes présenté dans le cadre de la programmation quadratique :

$$f(x) = \frac{1}{2}x^T Qx - b^T x \Rightarrow \nabla f(x) = Qx - b, \nabla^2 f(x) = Q$$

Où Q est une matrice symétrique $n \times n$ **définie positive**.

Définition :

- Deux vecteurs d^1 et d^2 sont **Q -orthogonaux** ou conjugués par rapport à Q si $d^{1T} Q d^2 = 0$
- Un ensemble fini de vecteurs distincts non nuls $\{d^0, d^1, \dots, d^k\}$ est dit conjugué par rapport à une matrice symétrique réelle Q , si

$$(d^i)^T Q d^j = 0 \quad \forall i \neq j$$

Théorème 1 : Indépendance linéaire des vecteurs conjugués

Si les vecteurs non nuls d^0, d^1, \dots, d^{n-1} forment un ensemble conjugué par rapport à une matrice définie positive Q , alors ils sont linéairement indépendants (forme une base).

Gradient Conjugué: Méthode fondamentale des directions conjuguées

$$x \in \mathbb{R}^2, \quad d^{1T} Q d^2 = 0$$

- Si $Q = I$
 - $Q = I = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$
 - $d^1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, d^2 = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$
 - $d^{1T} Q d^2 = (2 \ 1) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = (2 \ 1) \begin{pmatrix} 1 \\ -2 \end{pmatrix} = 2 - 2 = 0$
 - d^1 et d^2 sont orthogonaux
- Si $Q = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$
 - $d^1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, d^2 = \begin{pmatrix} 1 \\ -2 \end{pmatrix} \Rightarrow d^{1T} Q d^2 = (2 \ 1) \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = (2 \ 1) \begin{pmatrix} -3 \\ 0 \end{pmatrix} = -6 \neq 0$
 - $d^1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, d^2 = \begin{pmatrix} 1 \\ -2 \end{pmatrix} \Rightarrow (0 \ 1) \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = (0 \ 1) \begin{pmatrix} -3 \\ 0 \end{pmatrix} = 0$
 - $d^{1T} d^2 = (0 \ 1) \begin{pmatrix} 1 \\ -2 \end{pmatrix} = -2 \neq 0$

Gradient Conjugué: Principe


Soit $\{d^0, d^1, \dots, d^{n-1}\}$ ensemble conjugué

Le calcul de x^* peut être considéré comme un calcul itératif dans lequel n ajustements successifs de $\alpha_k d^k$ sont effectués à un point initial x^0 . Par ailleurs, la séquence générée par la relation récursive

- $x^{k+1} = x^k + \alpha_k d^k$ avec $(d^i)^T Q d^j = 0 \quad \forall i \neq j$
- $\alpha_k = \frac{(d^k)^T d_k}{(d^k)^T Q d_k}$
- Et x^k converge quand $k = n - 1$ à $x^n = x^* = \sum_{k=0}^{n-1} \alpha_k d^k$
- Gradient Conjugué
 - $x^0, d^0 = -\nabla f(x^0)$
 - $x^{k+1} = x^k + \alpha_k d^k$
 - $\alpha_k = \frac{(d^k)^T d_k}{(d^k)^T Q d_k}$
 - Et x^k converge quand $k = n - 1$ à $x_n = x^* = \sum_{k=0}^{n-1} \alpha_k d^k$

Gradient Conjugué:

$$Q = I$$



Gradient Conjugué: Algorithme $d^{kT} Q d^k > 0$

- **Entrée :**

- x^0 : Réel (point initial)

- $f(x) = \frac{1}{2} x^T Q x - b^T x$: Fonction ($f: \mathbb{R}^n \rightarrow \mathbb{R}^1$ et $f \in C^2$, Q définie positive , $d^{kT} Q d^k > 0$

- **Sortie :** x^* : Réel (point de sortie)

- **Début :**

- $d^0 = -\nabla f(x^0)$, $k = 0$

- **FOR ($k = 0 : n - 1$)**

- $\alpha_k = \frac{(d^k)^T d^k}{d^{kT} Q d^k} \Rightarrow x^{k+1} = x^k + \alpha_k d^k$

- $\beta_k = \frac{\nabla f(x^{k+1})^T Q d^k}{d^{kT} Q d^k} \Rightarrow d^{k+1} = -\nabla f(x^{k+1}) + \beta_k d^k$

- $k = k + 1$

- **ENDFOR**

- **RETURN** $x^* = x^n$

- **Fin**

Gradient Conjugué: Exemple 1: $b = 0, n = 2$

Soit le problème : $\min_{x \in \mathbb{R}^n} f(x_1, x_2) = \frac{1}{2}(x_1^2 + x_2^2) = \frac{1}{2}x^T Q x$

On a : $\nabla f(x_1, x_2) = Qx = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ et $\nabla^2 f(x_1, x_2) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = Q$

Considérer la solution initiale $x^0 = (x_1^0, x_2^0)^T = (2, 1)^T = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$

Itération 1:

- $x^0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, d^0 = -\nabla f(x^0) = \begin{pmatrix} -2 \\ -1 \end{pmatrix}$

Itération 2:

- $\alpha_0 = \frac{(d^0)^T d^0}{d^{0T} Q d^0} = \frac{(-2, -1) \begin{pmatrix} -2 \\ -1 \end{pmatrix}}{(-2, -1) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -2 \\ -1 \end{pmatrix}} = \frac{5}{(-2, -1) \begin{pmatrix} -2 \\ -1 \end{pmatrix}} = \frac{5}{5} = 1$

- $x^1 = x^0 + \alpha_0 d^0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix} + 1 \times \begin{pmatrix} -2 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \nabla f(x^1) = \nabla f(x_1^1, x_2^1) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

- $\beta_0 = \frac{\nabla f(x^1)^T Q d^0}{d^{0T} Q d^0} = \frac{(0, 0) \begin{pmatrix} -2 \\ -1 \end{pmatrix}}{(-2, -1) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -2 \\ -1 \end{pmatrix}} = \frac{0}{5} = 0$

- $d^1 = -\nabla f(x^1) + \beta_0 d^0 = -\begin{pmatrix} 0 \\ 0 \end{pmatrix} + 0 \times \begin{pmatrix} -2 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

Gradient Conjugué: Exemple2

Soit la fonction à minimiser :

$$f(x) = 4x_1^2 + 4x_2^2 - 4x_1x_2 - 12x_2 = \frac{1}{2} (x_1, x_2) \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - (0, 12) \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

On a :

- $\nabla f(x) = [8x_1 - 4x_2, -4x_1 + 8x_2 - 12]^T = \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \begin{pmatrix} 0 \\ 12 \end{pmatrix}$
- $\nabla^2 f(x) = \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} = Q$ et $b = \begin{pmatrix} 0 \\ 12 \end{pmatrix}$

Itération 1:

$$\bullet \quad x^0 = \begin{pmatrix} -\frac{1}{2} \\ 1 \end{pmatrix} \Rightarrow d^0 = -\nabla f(x^0) = -\left(\begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} -\frac{1}{2} \\ 1 \end{pmatrix} - \begin{pmatrix} 0 \\ 12 \end{pmatrix} \right) = -\left(\begin{pmatrix} -8 \\ 10 \end{pmatrix} - \begin{pmatrix} 0 \\ 12 \end{pmatrix} \right) = \begin{pmatrix} 8 \\ 2 \end{pmatrix}$$

Itération 2:

- $\alpha_0 = \frac{(d^0)^T d^0}{d^0{}^T Q d^0} = \frac{(8, 2) \begin{pmatrix} 8 \\ 2 \end{pmatrix}}{(8, 2) \begin{pmatrix} 8 & -4 \\ -4 & 8 \end{pmatrix} \begin{pmatrix} 8 \\ 2 \end{pmatrix}} = \frac{68}{(8, 2) \begin{pmatrix} 56 \\ -16 \end{pmatrix}} = \frac{68}{416} = \frac{17}{104}$
- $x^1 = x^0 + \alpha_0 d^0 = \begin{pmatrix} -\frac{1}{2} \\ 1 \end{pmatrix} + \frac{17}{104} \begin{pmatrix} 8 \\ 2 \end{pmatrix} = \begin{pmatrix} -\frac{11}{52} \\ \frac{26}{52} \\ \frac{69}{52} \end{pmatrix}$
- $\beta_0 = \frac{\nabla f(x^1)^T Q d^0}{d^0{}^T Q d^0} \Rightarrow d^1 = -\nabla f(x^1) + \beta_0 d^0$

Gradient Conjugué: Convergence

Théorème : (Théorème des directions conjuguées)

Supposons que la matrice Q est symétrique définie positive.

Soit $\{d^k\}_{k=0}^{n-1}$ **un ensemble de n vecteurs non-nuls qui sont Q -orthogonaux deux à deux.**

Etant donné un point $x^0 \in \mathbb{R}^n$ quelconque, la suite $\{x^k\}$ générée comme suit :

$$x^{k+1} = x^k + \alpha_k d^k, \quad k = 0, \dots, n-1$$

Où

$$\alpha_k = -\frac{\nabla f(x^k)^T d^k}{d^k{}^T \nabla^2 f(x^k) d^k} = -\frac{(Qx^k - b)^T d^k}{d^k{}^T Q d^k}$$

Converge vers l'unique minimum x^* de $f(x) = \frac{1}{2}x^T Qx - b^T x$ après n itérations (i. e., $x^* = x^n$)

Algorithme de Newton

- 1. Principe**
- 2. Algorithme**
- 3. Exemple**
- 4. convergence**

Algorithme de Newton: Principe

La méthode de Newton est un processus itératif pour construire une suite de points $\{x^k\}$ en partant d'un point x^0 dans le voisinage d'une solution optimale x^* .

Pour obtenir x^{k+1} , considérons l'approximation quadratique de f .

$$Q_k(x) = f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k)$$

x^{k+1} est le point où le gradient de l'approximation $Q_k(x)$ s'annule :

$$\nabla Q_k(x^{k+1}) = \nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0 \Rightarrow x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

Il faut noter que le Hessien $\nabla^2 f(x^k)$ doit être une matrice non-singulière.

La méthode newton est itérative où la direction d^k au point x^k est $d^k = -[\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$

- d^k est bien **une direction de descente** si le Hessien $\nabla^2 f(x^k)$ est une matrice positive définie

et si $\nabla f(x^k) \neq 0$: $\nabla f(x^k)^T d^k = -\nabla f(x^k)^T [\nabla^2 f(x^k)]^{-1} \nabla f(x^k) < 0$

- Pas optimal α_k défini comme suivant:

$$f(x^{k+1}) = f\left(x^k - \alpha_k [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)\right) = \min_{\alpha \geq 0} \left\{ f\left(x^k - \alpha [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)\right) \right\}$$

Algorithme de Newton: Principe

- Pour contrer la difficulté de choisir x^0 dans le voisinage de x^* où $\nabla f(x^*) = 0$
- Si le Hessien $\nabla^2 f(x^k)$ n'est pas une matrice positive définie, considérons la direction d^k suivante au point x^k :

$$d^k = -[\varepsilon_k I + \nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$

- Où I est la matrice identité et où $[\varepsilon_k I + \nabla^2 f(x_k)]$ a toute ses valeurs propres positives (i.e., est définie positive).

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix} \Rightarrow \nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial^2 x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_1 \partial x_n} & \cdots & \frac{\partial^2 f}{\partial^2 x_n} \end{pmatrix}$$

- Si $f \in \mathcal{C}^2$ alors $\forall i \neq j \quad \frac{\partial^2 f}{\partial x_j \partial x_i} = \frac{\partial^2 f}{\partial x_i \partial x_j}$

Algorithme de Newton:(Algorithme)

Entrée :

- x^0 : Réel (point initial)
- δ : Réel (la tolérance)
- f : Fonction ($f: \mathbb{R}^n \rightarrow \mathbb{R}^1$ et $f \in C^1$)

Sortie :

- x^* : Réel (point de sortie)

Début :

- $k = 0$
- $d^0 = -[\nabla^2 f(x^0)]^{-1} \nabla f(x^0)$
- **WHILE** ($\|d^k\| > \delta$) {
 - Déterminer α_k tel que $\alpha_k = \underset{\alpha \geq 0}{\operatorname{argmin}} \{f(x^k - \alpha d^{k+1})\}$ le pas optimal
 - $x^{k+1} = x^k - \alpha_k d^k$
 - IF ($\nabla^2 f(x^{k+1})$ est définie positive) $d^{k+1} = -[\nabla^2 f(x^{k+1})]^{-1} \nabla f(x^{k+1})$
 - ELSE $d^k = -[\varepsilon_k I + \nabla^2 f(x^k)]^{-1} \nabla f(x^k)$
 - $k = k + 1$ }
- **RETURN** $x^* = x^k$

Fin

Algorithme de Newton: Exemple

Entrée :

- $\min_{x \in \mathbb{R}^n} f(x_1, x_2) = \frac{1}{2}(x_1^2 + x_2^2), \delta = 10^{-2}$
- $\nabla f(x_1, x_2) = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}, \nabla^2 f(x_1, x_2) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$
- $x^0 = (x_1^0, x_2^0)^T = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \Rightarrow \nabla f(x^0) = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$

Itération 1:

- $d^0 = -[\nabla^2 f(x^0)]^{-1} \nabla f(x^0) = -\nabla f(x^0) = -\begin{pmatrix} 2 \\ 1 \end{pmatrix}$
- $\alpha_0 = \operatorname{argmin}_{\alpha > 0} \varphi(\alpha)$
- $\varphi(\alpha) = f(x^0 + \alpha d^0) = \frac{1}{2}((2 - 2\alpha)^2 + (1 - \alpha)^2) \Rightarrow \varphi'(\alpha) - 5 + 5\alpha = 0 \Rightarrow \alpha_0 = 1$
- $x^1 = x^0 + \alpha_0 d^0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix} - \alpha_0 \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 2-2\alpha_0 \\ 1-\alpha_0 \end{pmatrix} \Rightarrow x^1 = \begin{pmatrix} 2-2\alpha_0 \\ 1-\alpha_0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

Itération 2:

- $d^1 = -[\nabla^2 f(x^1)]^{-1} \nabla f(x^1) = -\nabla f(x^1) = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \|d^1\| = 0 < \delta$ Stop

Sortie : $x^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

Algorithme de Newton: Convergence

Théorème de Convergence d'ordre 2 :

Soit $f \in C^3$, sur \mathbb{R}^n , et supposons que dans le minimum local x^* , le Hessien $H(x^*)$ Est défini positive, alors si x^0 est choisi suffisamment près de x^* . Les points générés par la méthode de Newton converge vers x^* . Avec **l'ordre de convergence au moins 2.**

Théorème de Convergence de méthode de Newton modifié (cas quadratique)

Soit x^* un minimum unique de la fonction, définissons $E(x) = \frac{1}{2}(x - x^*)^T Q (x - x^*)$ alors pour algorithmes de la forme $x^{k+1} = x^k - \alpha_k S^k \nabla f(x^k)$

- Avec $S_k = [\nabla^2 f(x)]^{-1}$ dans le cas de Newton pure
- on a pour chaque itération k :

$$E(x^{k+1}) \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 E(x^k)$$

- Où λ_1 et λ_n sont respectivement le petit et la plus grande valeur propre de la matrice $S_k Q$.

Méthode de Quasi-Newton

- 1. Principe**
- 2. Algorithme général**
- 3. Variances**
- 4. Davidon–Fletcher–Powell (DFP)**

Méthode de Quasi-Newton : Principe

L'idée fondamentale derrière la plupart des méthodes de quasi-Newton est d'essayer de construire une approximation H^k l'inverse de Hessien $\nabla^2 f(x^k)^{-1}$, en utilisant l'information recueillie au cours du processus de descente.

- $(\nabla^2 f(x^k) + \varepsilon)^{-1} \approx H^k \Leftrightarrow B^k \approx \nabla^2 f(x^k) + \varepsilon \Leftrightarrow (B^k)^{-1} = H^k$

Pour obtenir x^{k+1} , considérons l'approximation quadratique de f .

- $Q_k(x) = f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T B^k (x - x^k)$
- x^{k+1} est le point où le gradient de l'approximation $Q_k(x)$ s'annule :
- $\nabla Q_k(x^{k+1}) = \nabla f(x^k) + B^k (x^{k+1} - x^k) = 0 \Rightarrow x^{k+1} = x^k - H^k \nabla f(x^k)$

Soit f une fonction dans \mathbb{R}^n de C^2 si pour deux points x^{k+1}, x^k on définit :

- $g_{k+1} = \nabla f(x^{k+1})$ et $g_k = \nabla f(x^k)$
 - $s^k = x^{k+1} - x^k = \alpha_k d^k$
 - $y^k = g_{k+1} - g_k$
- alors :

$$g_{k+1} - g_k \approx B^{k+1} s^k \Leftrightarrow s^k \approx H^{k+1} (g_{k+1} - g_k)$$

Méthode de Quasi-Newton : Algorithme Général

Entrée :

- x^0 : Réel (point initial)
- δ : Réel (la tolérance)
- f : Fonction ($f: \mathbb{R}^n \rightarrow \mathbb{R}^1$ et $f \in C^1$)

Sortie : x^* : Réel (point de sortie)

Début : $k = 0$, $g^0 = \nabla f(x^0)^T$, $H^0 = I$

WHILE ($\|g^k\| > \delta$) {

$$d^k = -H^k g^k$$

Déterminer $\alpha_k = \underset{\alpha \geq 0}{\operatorname{argmin}} \{f(x^k - \alpha d^k)\}$

$$x^{k+1} = x^k - \alpha_k d^k, \quad g^{k+1} = \nabla f(x^{k+1})^T$$

Déterminer H^{k+1}

$$k = k + 1\}$$

ENDWHILE

$$x^* = x^k, \text{ RETURN } x^*$$

Fin

Méthode de Quasi-Newton : Variances

Limite de Méthode Newton:

- Il exige que le Hessien soit défini positif, ce qui n'est pas toujours vrai pour chaque itération.
- Eviter de calculer le Hessien $\nabla^2 f(x^k)^{-1}$ et son inverse à chaque itération.

Solution:

Nous utilisons plutôt une matrice H^k définie positive qui est modifiée d'une itération à l'autre, il existe certains algorithmes pour calculer H^k :

- **Symmetric rank-one:** SR1
- **Davidon–Fletcher–Powell:** DFP, La matrice est H^{k+1} est déterminée comme suivant
 - $H^{k+1} = H^k + A^k + B^k$: $A^k = \frac{\alpha_k d^k d^{kT}}{d^{kT} y^k}$, $B^k = \frac{-H^k y^k (H^k y^k)^T}{y^{kT} H^k y^k}$, $y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$
- **Broyden–Fletcher–Goldfarb–Shanno** BFGS

Méthode de Quasi-Newton : Davidon–Fletcher–Powell

Exemple

$$\min_{x \in \mathbb{R}^2} f(x_1, x_2) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$$

- $\nabla f(x) = \begin{pmatrix} 1 + 4x_1 + 2x_2 \\ -1 + 2x_1 + 2x_2 \end{pmatrix}$

Entrée:

- $x^0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, H^0 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \delta = 0.01, \nabla f(x^0) = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$
- $k = 0$

While $\nabla f(x^0) = \begin{pmatrix} 1 \\ -1 \end{pmatrix} \Rightarrow \|\nabla f(x^0)\| = \sqrt{2} > \delta$

Itération 1 :

- Calcul de d^0 : $d^0 = -H^0 \nabla f(x^0) = -\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$

Calcul de pas optimal α_0

- $\varphi(\alpha) = f(x^0 + \alpha d^0) = f\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix} + \alpha \begin{pmatrix} -1 \\ 1 \end{pmatrix}\right) \Rightarrow \varphi(\alpha) = f(-\alpha, \alpha) = \alpha^2 - 2\alpha \Rightarrow \varphi'(\alpha_0) = 2\alpha - 2 = 0 \Rightarrow \alpha_0 = 1,$

Calcul de x^1

- $x^1 = x^0 + \alpha_0 d^0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + 1 \begin{pmatrix} -1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$

Calcul de $\nabla f(x^1)$

Méthode de Quasi-Newton : Davidon–Fletcher–Powell

- Calcul de H^1 :

- $y^0 = \nabla f(x^1) - \nabla f(x^0) = \begin{pmatrix} -1 \\ -1 \end{pmatrix} - \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} -2 \\ 0 \end{pmatrix}$

- $d^{0T}y^0 = (-1,1) \begin{pmatrix} -2 \\ 0 \end{pmatrix} = 2, \quad d^0 d^{0T} = \begin{pmatrix} -1 \\ 1 \end{pmatrix} (-1,1) = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$

- $H^0 y^0 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -2 \\ 0 \end{pmatrix} = \begin{pmatrix} -2 \\ 0 \end{pmatrix} \Rightarrow (H^0 y^0)^T = (-2, 0)$

- $y^{0T} H^0 y^0 = (-2, 0) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -2 \\ 0 \end{pmatrix} = (-2 \ 0) \begin{pmatrix} -2 \\ 0 \end{pmatrix} = 4$

- $A^0 = \alpha_0 \frac{d^0 d^{0T}}{d^{0T} y^0} = 1 \begin{pmatrix} \frac{1}{2} \\ \frac{1}{2} \end{pmatrix} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{pmatrix}$

- $B^0 = -\frac{(H^0 y^0)(H^0 y^0)^T}{y^{0T} H^0 y^0} = -\frac{\begin{pmatrix} -2 \\ 0 \end{pmatrix} (-2, 0)}{4} = -\frac{1}{4} \begin{pmatrix} 4 & 0 \\ 0 & 0 \end{pmatrix} = -\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$

- $H^1 = H^0 + A^0 + B^0 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{pmatrix} + \begin{pmatrix} -1 & 0 \\ 0 & 0 \end{pmatrix} \Rightarrow H^1 = \begin{pmatrix} 0.5 & -0.5 \\ -0.5 & 1.5 \end{pmatrix}$

Méthode de Quasi-Newton : Davidon–Fletcher–Powell

Itération 2 : $\|\nabla f_1\| = 1.4142 > \delta$

- Calcul de d^1

- $d^1 = -H^1 \nabla f(x^1) = -\begin{pmatrix} 0.5 & -0.5 \\ -0.5 & 1.5 \end{pmatrix} \begin{pmatrix} -1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

- Calcul de pas optimal α_1

- $\varphi(\alpha) = f(x^1 + \alpha d^1) = f\left(\begin{pmatrix} -1 \\ 1 \end{pmatrix} + \alpha \begin{pmatrix} 0 \\ 1 \end{pmatrix}\right) = f\left(\begin{pmatrix} -1 \\ 1 + \alpha \end{pmatrix}\right)$

- $\varphi(\alpha) = -1 - (1 + \alpha) + 2(-1)^2 + 2(-1)(1 + \alpha) + (1 + \alpha)^2$

- $\varphi(\alpha) = \alpha^2 - \alpha - 1 \Rightarrow \varphi'(\alpha_1) = 2\alpha - 1 = 0 \Rightarrow \alpha_1 = \frac{1}{2}$

- Calcul de x^2

- $x^2 = x^1 + \alpha_1 d^1 = \begin{pmatrix} -1 \\ 1 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 1.5 \end{pmatrix}$

- $\nabla f(x^2) = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \nabla f(x^2) = 0 < \delta \Rightarrow x^* = x^2 = \begin{pmatrix} -1 \\ 1.5 \end{pmatrix}$

Méthode de Quasi-Newton : Davidon–Fletcher–Powell

la variance DFP est une variance typique lequel est de rang 2, i.e., H^{k+1} est obtenu par addition de deux matrices symétrique à H^k , chacune de premier rang :


$$H^{k+1} = H^k + auu^T + bvv^T = H^k + A^k + B^k$$

Où , $u, v \in \mathbb{R}^n$, a et b sont des scalaire à déterminer, par l'équation de quasi-Newton :

$$H^k y^k + auu^T y^k + bvv^T y^k = s^k$$

Clairement, u et v sont non uniques, mais la solution la plus évident :

- $u = s^k, v = H^k y^k$
 - $s^k = x^{k+1} - x^k = \alpha_k d^k \rightarrow s^k s^{kT} = (\alpha_k)^2 d^k d^{kT}$
 - $\Rightarrow a = \frac{1}{u^T y^k} = \frac{1}{s^{kT} y^k} = \frac{1}{(\alpha_k d^k)^T y^k},$
 - $\Rightarrow b = -\frac{1}{v^T y^k} = -\frac{1}{y^{kT} H^k y^k}$
 - $\Rightarrow H^{k+1} = H^k + \frac{s^k s^{kT}}{s^{kT} y^k} - \frac{H^k y^k y^{kT} H^k}{y^{kT} H^k y^k}$



Méthode de Quasi-Newton : Davidon–Fletcher–Powell

Lemme 1 : (i. e., $\nabla f(x^k)^T d^k < 0$)

Si H^k est définie positive et $\nabla f(x^k) \neq 0$, alors d^k est une direction de descente à x^k .

Preuve:

Par définition $d^k = -H^k \nabla f(x^k)$ donc $\nabla f(x^k)^T d^k = -\nabla f(x^k)^T H^k \nabla f(x^k) < 0$

Sous les hypothèses que H^k est définie positive et $\nabla f(x^k) \neq 0$

Lemme 2 : (d^k est perpendiculaire au $\nabla f(x^{k+1})$)

Si H^k est définie positive, alors $d^{kT} \nabla f(x^{k+1}) = 0$

Preuve:

Si $d^k = 0$, la preuve est complétée

Si $d^k \neq 0$, pour $\alpha \geq 0$ définissons les fonctions: $\varphi(\alpha) = f(x^k + \alpha d^k)$ et $g(\alpha) = x^k + \alpha d^k$

Puisque $\varphi: \mathbb{R} \rightarrow \mathbb{R}$, par dérivation en chaîne on a $\varphi'(\alpha) = (f \circ g(\alpha))' = d^{kT} \nabla f(x^k + \alpha d^k)$

Puisque α_k est un minimum local de $\varphi(\alpha)$, alors

$$\bullet \varphi'(\alpha_k) = 0 \implies \varphi'(\alpha_k) = d^{kT} \nabla f(x^k + \alpha_k d^k) = d^{kT} \nabla f(x^{k+1}) \implies d^{kT} \nabla f(x^{k+1}) = 0$$

Méthode de Quasi-Newton : Davidon–Fletcher–Powell

Lemme3 :

Soit H^k est définie positive alors la formule DFP produit H^{k+1} définie positive si et seulement si $(d^k)^T y^k > 0$.

Preuve

La preuve par induction sur k pour $k = 0, H^0 = I$ est définie positive

Supposons que H^k est définie positive. Alors

$$\begin{aligned} \bullet \quad x^k H^{k+1} x &= x^T H^k x + x^T A^k x + x^T B^k x = x^T H^k x + \frac{\alpha_k^2 x^T d^k d^{kT} x}{\alpha_k d^{kT} y^k} - \frac{x^T H^k y^k (H^k y^k)^T x}{y^{kT} H^k y^k} \\ \bullet \quad \Rightarrow x^k H^{k+1} x &= \frac{x^T H^k x y^{kT} H^k y^k - x^T H^k y^k y^{kT} H^k x}{y^{kT} H^k y^k} + \frac{(\alpha_k d^{kT} x)^2}{\alpha_k d^{kT} y^k} \end{aligned}$$

Mais puisque H^k est définie positive, il découle de l'inégalité de Schwartz que $x^T H^{k+1} x \geq \frac{(\alpha_k d^{kT} x)^2}{\alpha_k d^{kT} y^k}$

Rappelons que $y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$ en utilisant les lemmes 2 et 1 On obtient:


$$\alpha_k d^{kT} y^k = \alpha_k d^{kT} [\nabla f(x^{k+1}) - \nabla f(x^k)] = -\alpha_k d^{kT} \nabla f(x^k) > 0$$

Recherche linéaire du pas approchée

1. Introduction
2. Règles sur le pas approchée:
 1. Armijo
 2. Goldstein
 3. Wolfe

Recherche linéaire du pas approchée: Introduction

- $\alpha_k \in [I, S]$



Recherche linéaire du pas approchée: Introduction

Dans plusieurs méthodes itératives, pour identifier x^{k+1} il faut résoudre le problème unidimensionnelle

$$\min_x \varphi(\alpha) = \min_{\alpha > 0} f(x^k + \alpha d^k) = f(x^k + \alpha_k d^k) = \varphi(\alpha_k)$$

Afin de déterminer le pas optimal

- Au lieu d'effectuer la recherche du pas optimal qui pourrait être coûteuse, parfois il est préférable de trouver juste un pas qui au moins **assure la convergence**.
- Soit l'approximation linéaire de φ à 0 est obtenue à partir du développement de Taylor d'ordre 1 :

$$\varphi(\alpha) \approx \bar{\varphi}(\alpha) = \varphi(0) + \varphi'(0)\alpha$$

Tel que :

$$\bar{\varphi}(0) = \varphi(0) \text{ et } \bar{\varphi}'(\alpha) = \varphi'(0)$$

Recherche linéaire du pas approchée: Introduction

Pour déterminer une approximation acceptable du pas optimal α_k , nous considérons l'approximation suivant de φ


$$\hat{\varphi}(\alpha) = \varphi(0) + \varepsilon \varphi'(0) \alpha$$

Pour une valeur fixée de ε entre 0 et 1 ($\varepsilon = 0.2$, par exemple)

Une valeur α est acceptable tout en n'étant pas trop grande,

Si $\varphi(\alpha)$ n'excède pas l'approximation $\hat{\varphi}(\alpha)$, i.e.

$$\varphi(\alpha) \leq \hat{\varphi}(\alpha) = \varphi(0) + \varepsilon \varphi'(0) \alpha \quad (3.3)$$



Recherche linéaire du pas approchée: Règle d'Armijo

Pour s'assurer que la valeur de α choisie n'est pas trop petite α doit satisfaire un des tests additionnels suivants :


Règle d'Armijo :

la valeur α est telle que

$$\varphi(\eta\alpha) > \hat{\varphi}(\eta\alpha) = \varphi(0) + \varepsilon\varphi'(0)\eta\alpha \quad (3.4)$$

Où $\eta > 1$ ($\eta = 2$, par exemple)

Ainsi, si α est multiplié par un facteur égal à η alors la relation (3.3) n'est plus vérifiée.




Recherche linéaire du pas approchée: Règle d'Armijo

$$\varphi(2\alpha) > \hat{\varphi}(2\alpha) = \varphi(0) + \varepsilon\varphi'(0)2\alpha$$

Algorithme de la règle d'Armijo :


- Choisir une certaine valeur de α
- Si (3.3) est satisfaite, multiplier à répétition par η jusqu'à ce que (3.3) ne soit plus satisfaite.
- Alors la valeur précédente parmi la suite des valeurs obtenues est celle du pas retenu.



Recherche linéaire du pas approchée: Règle d'Armijo :

Algorithme de la règle d'Armijo :

- Si (3.3) n'est pas satisfaite, diviser à répétition par η jusqu'à ce que (3.3) soit vérifiée.
- Cette dernière valeur satisfaisant (3.3) est celle du pas retenu puisque la multiplier par η entraîne que (3.3) n'est plus vérifiée.



Recherche linéaire du pas approchée: Règle d'Armijo

Algorithme de la règle d'Armijo

L'essentiel de la règle d'Armijo c'est que le pas α est accepté si et seulement si il satisfait au (3) et (4).

$$\varphi(\alpha) \leq \hat{\varphi}(\alpha) = \varphi(0) + \varepsilon \varphi'(0)\alpha \quad (3)$$

$$\varphi(\eta\alpha) > \hat{\varphi}(\eta\alpha) = \varphi(0) + \varepsilon \varphi'(0)\eta\alpha \quad (4)$$

Algorithme:

Entrée: $\alpha_0 > 0, \varepsilon \in (0,1), \eta > 1$

Mettre $\alpha = \alpha_0$

- Si α vérifier (3)
 - Effectuer **Parcours en avant** jusqu'à α vérifier (4)
- Sinon (**α ne vérifier pas (3) $\Rightarrow \alpha$ vérifier (4)**)
 - Effectuer **Parcours en arrière** avant jusqu'à α vérifier (3)

Recherche linéaire du pas approchée: Règle d'Armijo

- **Parcours en avant: sous hypothèse que 4 n'est pas encore vérifié**
 1. Entrée: $\alpha_0 > 0, \varepsilon \in (0,1), \eta > 1$
 2. Mettre $\alpha = \alpha_0$
 3. Si $\varphi(\eta\alpha) > \hat{\varphi}(\eta\alpha) = \varphi(0) + \varepsilon\varphi'(0)\eta\alpha$ ((4) est satisfait)
retourner α et arrêter. Sinon **Substitue $\alpha = \eta\alpha$** et retourne à 2
- **Parcours en arrière: sous hypothèse que 3 n'est pas encore vérifié**
 1. Entrée: $\alpha_0 > 0, \varepsilon, \eta > 1$
 2. Mettre $\alpha = \alpha_0$
 3. Si $\varphi(\alpha) \leq \varepsilon\alpha\varphi'(0) + \varphi(0)$ ((3) est satisfaite)
retourner α et arrêter. Sinon **Substitue $\alpha = \frac{\alpha}{\eta}$** et retourne à 2

Recherche linéaire du pas approchée: Règle de Goldstein


Pour s'assurer que la valeur de α choisie n'est pas trop petite α doit satisfaire un des tests additionnels suivants :

Règle de Goldstein :

la valeur α est telle que

$$\varphi(\alpha) > \varphi(0) + (1 - \rho)\varphi'(0)\alpha \quad (3.5)$$

$$\text{où } 0 < \rho < \frac{1}{2}$$



Recherche linéaire du pas approchée: Règle de Goldstein

Algorithme Goldstein

Etape 1 : Prendre α_0 dans $[0, +\infty[$ où $[0, \alpha_{max}[$

- Calculer $\varphi(0)$, $\varphi'(0)$. Prendre $\rho \in (0, \frac{1}{2})$, $t > 1$,
- Mettre $\alpha_0 = 0$, $b_0 = +\infty$ ou α_{max} $k = 0$

Etape 2 : Vérifier la règle 3 : calcule $\varphi(\alpha_k)$


- Si $\varphi(\alpha_k) \leq \varphi(0) + \rho\alpha_k\varphi'(0)$ Passer à l'étape 3
- Sinon mettre $a_{k+1} = \alpha_k$ et $b_{k+1} = \alpha_k$ passer à l'étape 4

Etape 3 : Vérifier la règle 4 :

- Si $\varphi(\alpha_k) \geq \varphi(0) + (1 - \rho)\alpha_k\varphi'(0)$ arrête, et renvoyer α_k
- sinon, mettre $a_{k+1} = \alpha_k$, $b_{k+1} = b_k$
- Si $b_{k+1} < +\infty$, passer à l'étape 4
- sinon mettre $\alpha_{k+1} = t\alpha_k$ et $k = k + 1$, Et passer à l'étape 2.

Etape 4 : Choisir un nouveau point mettre $\alpha_{k+1} = \frac{a_{k+1} + b_{k+1}}{2}$

- Et $k = k + 1$ et passer à l'étape 2.



Recherche linéaire du pas approchée: Règle de Wolfe


Pour s'assurer que la valeur de α choisie n'est pas trop petite α doit satisfaire un des tests additionnels suivants :

Règle de Wolfe :

Une valeur α est acceptable tout en préservant la convergence,

Si $\varphi'(\alpha)$ est plus grande que $\bar{\varepsilon}\varphi'(0)$, i.e.

$$\varphi'(\alpha) \geq \bar{\varepsilon}\varphi'(0) \quad \text{où} \quad 0 < \bar{\varepsilon} < \frac{1}{2} \quad (3.4)$$



Recherche linéaire du pas approchée: Convergence

Théorème :

- Soit α_k dans algorithme 3 qui est défini par règle de Goldstein ou Wolfe,
- soit s^k tel que à $\theta_k \leq \frac{\pi}{2} - \mu$

Si ∇f existe et uniformément continue sur l'ensemble $\Omega = \{x \mid f(x) \leq f(x_0)\}$ alors $\nabla f(x^k) = 0$ Pour certains k , ou $f(x^k) \rightarrow -\infty$, ou $\nabla f(x^k) \rightarrow 0$.