

# Optimisation Non linéaire

Par

Professeur Abdellatif El Afia

## Chapitre 7

# Dualité lagrangienne

Professor Abdellatif El Afia

# Dualité lagrangienne

$$\text{Primal} \begin{cases} \text{Min} & f(x) \\ \text{s.t} & f_i(x) \leq 0 \quad i = 1, \dots, m \\ & x \in X \subseteq \mathbb{R}^n \end{cases}$$

- $D_R = \{x \in X \subseteq \mathbb{R}^n : f_i(x) \leq 0 \quad i = 1, \dots, m\}$

## Définition

Le problème dual lagrangien associé au problème primal relativement au  $D_R$ , s'écrit :

$$\text{Dual} \begin{cases} \text{Max} & g(\lambda) = \inf_{x \in \mathbb{R}^n} \left\{ f(x) + \sum_{i=1}^m \lambda_i f_i(x) \right\} \\ \text{s.t} & \lambda \in \Lambda \end{cases}$$

- $g(\lambda) = \inf_{x \in X} \{f(x) + \sum_{i=1}^m \lambda_i f_i(x)\}$  est la fonction objective du dual
- $\Lambda = \{\lambda \in \mathbb{R}^m : \lambda \geq 0\}$  est l'ensemble des contraintes du dual problème

## Dualité lagrangienne: Exemple

Soit le problème quadratique convexe suivant :

$$\begin{cases} \text{Min} & \frac{1}{2} x^T Q x + c^T x \\ \text{s. t} & Ax \geq b \\ & x \in X \subseteq \mathbb{R}^n \end{cases}$$

Où  $Q$  est symétrique et définie positive.

Pour construire le problème dual, on commence par réécrire les contraintes d'inégalité comme suit  $b - Ax \leq 0$ , en suite nous construisons le Lagrangien :

$$L(x, \lambda) = \frac{1}{2} x^T Q x + c^T x + \lambda^T (b - Ax) = \lambda^T b + (c^T - A^T \lambda)^T x + \frac{1}{2} x^T Q x$$

La fonction duale est :

$$\begin{aligned} g(\lambda) &= \min_{x \in \mathbb{R}^n} L(x, \lambda) = \min_{x \in \mathbb{R}^n} \lambda^T b + (c^T - A^T \lambda)^T x + \frac{1}{2} x^T Q x \\ &= \lambda^T b + \min_{x \in \mathbb{R}^n} (c^T - A^T \lambda)^T x + \frac{1}{2} x^T Q x \end{aligned}$$

## Dualité lagrangienne: Exemple

Pour une valeur de  $\lambda$  quelconque, soit  $x^*$  la valeur optimale de  $\min_{x \in \mathbb{R}^n} (c^T - A^T \lambda)^T x + \frac{1}{2} x^T Q x$

Comme cette expression est une fonction quadratique convexe le gradient du lagrangien en  $x^*$  est nul :

$$\nabla_x L(x^*, \lambda) = (c - A^T \lambda) + Q x^* = 0$$

L'expression de  $x^*$  est alors donnée par :  $x^* = -Q^{-1}(c - A^T \lambda)$

La fonction duale devient alors :  $g(\lambda) = L(x^*, \lambda) = \lambda^T b - \frac{1}{2} (c - A^T \lambda)^T Q^{-1} (c - A^T \lambda)$

Comme le problème dual est défini par :  $\max_{\lambda \geq 0} g(\lambda)$

Le dual du problème quadratique convexe est donc donné par :

$$\begin{cases} \text{Max} & \lambda^T b - \frac{1}{2} (c - A^T \lambda)^T Q^{-1} (c - A^T \lambda) \\ \text{s. t} & \lambda \geq 0 \\ & \lambda \in \mathbb{R}^m \end{cases}$$

# Dualité lagrangienne

## Théorème

La fonction objective du dual  $g(\lambda)$  est une fonction concave sur l'ensemble  $\Lambda$  pour toutes fonctions  $f$  et  $f_i$

## Preuve

Soient  $\lambda_1 \in \Lambda$ ,  $\lambda_2 \in \Lambda$  alors  $\lambda_1 \geq 0$  et  $\lambda_2 \geq 0$ , et soit  $\lambda = \theta\lambda_1 + (1 - \theta)\lambda_2 \in \Lambda$  avec  $\theta \in [0,1]$  alors

- $g(\lambda) = \inf_{x \in \mathbb{R}^n} \{f(x) + \sum_{i=1}^m \lambda_i f_i(x)\}$
- $g(\lambda) = \inf_{x \in \mathbb{R}^n} \{\theta(f(x) + \sum_{i=1}^m \lambda_{1_i} f_i(x)) + (1 - \theta)(f(x) + \sum_{i=1}^m \lambda_{2_i} f_i(x))\}$
- $\Rightarrow g(\lambda) \geq \theta \inf_{x \in \mathbb{R}^n} \{f(x) + \sum_{i=1}^m \lambda_{1_i} f_i(x)\} + (1 - \theta) \inf_{x \in \mathbb{R}^n} \{f(x) + \sum_{i=1}^m \lambda_{2_i} f_i(x)\}$
- $\Rightarrow g(\lambda) \geq \theta g(\lambda_1) + (1 - \theta)g(\lambda_2)$

D'où  $g(\lambda)$  est une fonction concave sur l'ensemble  $\Lambda$  pour toutes fonctions  $f$  et  $f_i$

# Dualité lagrangienne

## Théorème:

Soient  $A \subset \mathbb{R}^n$  et  $B \subset \mathbb{R}^m$ .

Si

- $A$  est convexe
- Pour toute valeur  $b \in B$ ,  $h(a, b): A \times B \rightarrow \mathbb{R}$  est convexe sur  $A$ ,

alors

- l'ensemble  $A^* = \{a \in A: l(a) = \sup_{b \in B} \{h(a, b)\} < \infty\}$  est convexe
- $l$  est convexe sur  $A^*$

## Définition

- La **valeur optimale** du problème **primal** est le infimum de la fonction  $f(x)$  sur  $D_R$
- La **valeur optimale** du problème **dual** est le supremum de la fonction  $g(\lambda)$  sur  $\Lambda$
- Par convention, le infimum (supremum) d'une fonction sur un ensemble vide est égal à  $\infty$  ( $-\infty$ ).

# Interprétation géométrique du problème dual

Soit

- $x \in \mathbb{R}^n$ , Posons  $(s, z) = (s_1, \dots, s_m, z) = (f_1(x), \dots, f_m(x), z)$
- $I = \{(s, z) \in \mathbb{R}^{m+1} : \exists x \in \mathbb{R}^n \text{ où } z \geq f(x) \text{ et } s \geq (f_i(x)), i = 1, \dots, m\}$

Cet ensemble est illustré par la figure

**Proposition:**

Si  $X$  est convexe et  $f$  et  $f_i, i = 1, \dots, m$  sont convexes sur  $X$  alors  $I$  est aussi convexe.


Maintenant, on définit l'hyperplan

$$H_{\lambda, \alpha} := \{(s, z) \in \mathbb{R}^{m+1} : \lambda^T s + z = \alpha\}$$

On dit que  $H_{\lambda, \alpha}$  est *support inférieur* de  $I$  si

$$\forall (s, z) \in I \quad \lambda^T s + z \geq \alpha$$

On définit aussi la droite





# Théorèmes de dualité

Pour le premier théorème de dualité faible, nous n'avons pas besoin d'hypothèses particulières sur  $X$ , ni sur les fonctions  $f$  et  $f_i, i = 1, \dots, m$ .

## Théorème de dualité faible

Si  $\bar{x}$  est une solution réalisable du primal et  $\bar{\lambda}$  une solution réalisable du dual, alors  $f(\bar{x}) \geq g(\bar{\lambda})$ .

### Preuve

Considérons la quantité  $f(\bar{x}) + \sum_{i=1}^m \bar{\lambda}_i f_i(\bar{x}) \leq f(\bar{x})$ , Puisque  $f_i(\bar{x}) \leq 0$  et  $\bar{\lambda}_i \geq 0, i = 1, \dots, m$ , D'autre part,

$$g(\bar{\lambda}) = \inf_{x \in X} \left\{ f(x) + \sum_{i=1}^m \bar{\lambda}_i f_i(x) \right\} \leq f(\bar{x}) + \sum_{i=1}^m \bar{\lambda}_i f_i(\bar{x})$$

Puisque  $\bar{x} \in X$

Donc  $g(\bar{\lambda}) = \inf_{x \in X} \{ f(x) + \sum_{i=1}^m \bar{\lambda}_i f_i(x) \} \leq f(\bar{x}) + \sum_{i=1}^m \bar{\lambda}_i f_i(\bar{x}) \leq f(\bar{x})$ .

# Théorèmes de dualité

## Définition: Point selle

$(x^*, \lambda^*)$  est dit point selle du Lagrangien  $L(x, \lambda)$  si

- $x^* \in X$  et  $\lambda^* \geq 0$
- $L(x^*, \lambda) \leq L(x^*, \lambda^*) \leq L(x, \lambda^*) \quad \forall x \in X, \forall \lambda \geq 0$

## Théorème 1:

$(x^*, \lambda^*)$  est un point selle du Lagrangien si et seulement si les trois conditions suivantes sont vérifiées :

$$\begin{cases} C_1: & L(x^*, \lambda^*) = g(\lambda^*) \\ C_2: & F(x^*) \leq 0 \\ C_3: & \lambda^{*T} F(x^*) = 0 \end{cases}$$

**En plus,**  $(x^*, \lambda^*)$  est point selle pour  $L(x, \lambda)$  si et seulement si les deux conditions suivantes sont vérifiées :

- $(x^*, \lambda^*)$  est respectivement, solution optimale du problème primal et dual
- Il n'y a pas de saut de dualité, c'est-à-dire que  $f(x^*) = g(\lambda^*)$

# Théorèmes de dualité

## Théorème 2 :

Supposons  $X = \mathbb{R}^n$  et  $f(x), f_1(x), \dots, f_m(x)$  sont convexes et différentiables, et  $(x^*, \lambda^*)$  satisfait les conditions de **K.K.T** alors  $x^*$  et  $\lambda^*$  sont solution du problème primal et dual sans saut de dualité.

$(x^*, \lambda^*)$  satisfait les conditions de **K.K.T** :

$$\begin{cases} \nabla f(x^*) + \lambda^{*T} \nabla F(x^*) = 0 \\ F(x^*) \leq 0 \\ \lambda^* \geq 0 \\ \lambda^{*T} F(x^*) = 0 \end{cases}$$

## Théorème 3 :

Si  $(x^*, \lambda^*)$  est un point selle de  $L$  alors

$$g^* = \sup_{\lambda \geq 0} \inf_{x \in X} L(x, \lambda) = L(x^*, \lambda^*) = \inf_{x \in X} \sup_{\lambda \geq 0} L(x, \lambda) = f^*$$

# Problème de programmation convexe

## Définition:

Un problème de programmation convexe est un problème d'optimisation sous la forme

$$(P) \begin{cases} \text{Min} & f_0(x) \\ \text{s.t} & f_i(x) \leq 0 \quad i \in I_1 \\ & h_i(x) = a_i^T x + b_i = 0 \quad i \in I_2 \\ & x \in \mathbb{R}^n \end{cases}$$

Où  $f_0(x), \{f_i(x)\}_{i \in I_1}$  sont des fonctions convexes continues sur  $\mathbb{R}^d$  et  $\{h_i(x)\}_{i \in I_2}$  sont des fonctions linéaires

## Théorème:

- Le domaine réalisable,  $D_F$ , est convexe  $D_F = \{x \in \mathbb{R}^d \mid f_i(x) \leq 0 \quad i \in I_1, h_i(x) = 0 \quad i \in I_2\}$
- L'ensemble solution de  $(P)$  est un ensemble fermé convexe
- Si  $x^*$  est la solution locale de  $(P)$  alors  $x^*$  est aussi la solution globale
- Si la fonction objectif  $f_0(x)$  est strictement convexe alors la solution de  $(P)$  est unique

# Problème de programmation convexe

**Definition: (Problème de programmation quadratique (QP))**

$$(QP) \begin{cases} \text{Min} & \frac{1}{2}x^T Qx + c^T x \\ \text{s.t} & \bar{A}x - \bar{b} \leq 0 \\ & Ax - b = 0 \\ & x \in \mathbf{QP} \end{cases}$$

Où  $Q \in \mathbb{R}^{n \times n}$ ,  $c \in \mathbb{R}^n$ ,  $\bar{A} \in \mathbb{R}^{m \times n}$ ,  $A \in \mathbb{R}^{p \times n}$ ,  $\bar{b} \in \mathbb{R}^m$ ,  $b \in \mathbb{R}^p$

**Si  $Q$  est semi-défini positif, alors le problème  $QP$  est une programmation convexe**

**Théorème:**

- L'ensemble  $D_F = \{x \in \mathbb{R}^d \mid \bar{A}x - \bar{b} \leq 0, Ax - b = 0\}$  est convexe
- L'ensemble solution de  $(QP)$  est un ensemble fermé convexe
- Si  $x^*$  est la solution locale de  $(QP)$  alors  $x^*$  est aussi la solution globale
- Si  $Q$  est définie positive alors La solution de  $(QP)$  est unique

# Problème de programmation convexe

## Définition:

Considérons le problème de programmation convexe ( $P$ ) avec la variable  $x$  étant partitionné sous la forme  $x = (x_1, x_2) \in \mathbb{R}^n$ .

$x_1^* \in \mathbb{R}^{m_1}$  est appelé sa solution par rapport à (w.r.t)  $x_1$  s'il existe un  $x_2^* \in \mathbb{R}^{n-m_1}$  tel que  $x^* = (x_1^*, x_2^*)$  est sa solution. L'ensemble de toutes les solutions par rapport à  $x_1$  est appelé l'ensemble de solutions par rapport à  $x_1$

## Théorème:

Si le problème de programmation convexe ( $P$ ) avec la variable  $x = (x_1, x_2) \in \mathbb{R}^n$ , alors

- son ensemble solution par rapport à  $x_1$  est un ensemble fermé convexe
- Si  $f_0(x) = F_1(x_1) + F_2(x_2)$  où  $F_1$  est strictement convexe de la variable  $x_1$  alors la solution de ( $P$ ) par rapport à  $x_1$  est unique lorsqu'elle a une solution

## Problème de programmation convexe

Considérons le problème de programmation convexe

$$\text{Primal } (P) \begin{cases} \text{Min} & f_0(x) \\ \text{s.t} & f_i(x) \leq 0 \quad i \in I_1 \\ & h_i(x) = a_i^T x + b_i = 0 \quad i \in I_2 \\ & x \in \mathbb{R}^n \end{cases}$$

où  $f_0(x) \in \mathcal{C}^2, \forall i \in I_1 \ f_i(x) \in \mathcal{C}^2$  et convexe dans  $\mathbb{R}^d$ ,

On part de l'estimation de sa valeur optimale

$$p^* = \inf \{f_0(x) | x \in D_F\} = \inf_{x \in D_F} f_0(x)$$

où  $D_F = \{x \in \mathbb{R}^d | f_i(x) \leq 0 \quad i \in I_1, h_i(x) = 0 \quad i \in I_2\}$

Introduisons la fonction lagrangienne

$$L(x, \lambda, \mu) = f_0(x) + \sum_{i \in I_1} \lambda_i f_i(x) + \sum_{i \in I_2} \mu_i h_i(x)$$

où  $\lambda = (\lambda_1, \dots, \lambda_m)^T$  et  $\mu = (\mu_1, \dots, \mu_p)^T$  sont des multipliers lagrangiens.

## Problème de programmation convexe: : Conditions d'optimalité

### Définition(Conditions de Karush-Kuhn-Tucker (KKT))

Considérons le problème principal de programmation convexe (P).  $x^*$  est dit satisfaire les conditions KKT s'il existe les multiplicateurs  $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)^T$  et  $\mu^* = (\mu_1^*, \dots, \mu_p^*)^T$  correspondant respectivement aux contraintes du problème primal (P) , telles que la fonction lagrangienne (P)

$$L(x, \lambda, \mu) = f_0(x) + \sum_{i \in I_1} \lambda_i f_i(x) + \sum_{i \in I_2} \mu_i h_i(x) \Rightarrow \nabla_x L(x, \lambda, \mu) = \nabla f_0(x) + \sum_{i \in I_1} \lambda_i \nabla f_i(x) + \sum_{i \in I_2} \mu_i \nabla h_i(x)$$

Satisfait

$$\text{KKT Conditions:} \left\{ \begin{array}{l} \nabla_x L(x^*, \lambda^*, \mu^*) = \nabla f_0(x^*) + \sum_{i \in I_1} \lambda_i^* \nabla f_i(x^*) + \sum_{i \in I_2} \mu_i^* \nabla h_i(x^*) = 0 \\ f_i(x^*) \leq 0 \quad i \in I_1 : |I_1| = m \\ h_i(x^*) = a_i^T x^* + b_i = 0 \quad i \in I_2 : |I_2| = p \\ \lambda_i^* f_i(x^*) = 0 \quad i \in I_1 \\ \lambda_i^* \geq 0 \quad i \in I_1 \end{array} \right.$$



## Problème de programmation convexe: Conditions d'optimalité

### Définition (Condition de Slater)

On dit que le problème primal de programmation convexe ( $P$ ) satisfait la condition de Slater s'il existe une solution réalisable  $x$  telle que:

$$\begin{cases} f_i(x) < 0 & i \in I_1 \\ h_i(x) = a_i^T x + b_i = 0 & i \in I_2 \end{cases}$$

Ou lorsque les premières contraintes d'inégalité de  $k$  sont des contraintes linéaires, il existe une solution réalisable  $x$  telle que :

$$\begin{cases} f_i(x) = a_i^T x + b_i \leq 0 & i \in I_1^k \\ f_i(x) < 0 & i \in I_1^{m-k} \\ h_i(x) = a_i^T x + b_i = 0 & i \in I_2 \end{cases}$$


### Théorème:

Considérons le problème primal de programmation convexe ( $P$ ) satisfaisant la condition de Slater. Si  $x^*$  est une solution alors  $x^*$  satisfait aux conditions KKT.

### Théorème:

Considérons le problème primal de programmation convexe ( $P$ ) satisfaisant la condition de Slater. Alors pour sa solution  $x^*$ , c'est une condition nécessaire et suffisante que  $x^*$  satisfait aux conditions KKT

# Hard margin SVC



- Distance from one point to the Separator:

$$D(x) = \frac{|w^T x + b|}{\|w\|}$$

Maximum margin before reaching the boundaries of both classes ( $|w^T x + b| = 1$ ):

$$m = \frac{1}{\|w\|}$$

- To maximize  $m$  is to minimize  $\|w\|$  while preserving the classification power:

$$SVC: \begin{cases} \text{Min} & \|w\| \\ \text{s.t} & y_i(w^T x_i + b) \geq 1 \quad i = 1, \dots, n \\ & w \in \mathbb{R}^d, b \in \mathbb{R} \end{cases}$$

# Hard margin SVC

$$SVC: \begin{cases} \text{Min} & \frac{1}{2} \|w\|^2 \\ \text{s.t} & y_i(w^T x_i + b) \geq 1 \quad i = 1, \dots, n \\ & w \in \mathbb{R}^d, b \in \mathbb{R} \end{cases}$$

## Theorem:

For a linearly separable problem, there exists a solution unique  $(w^*, b^*)$  to optimization problem *SVC* and the solution satisfies:

- $w^* \neq 0$
- $\exists j \in \{i \in \{1, \dots, n\} | y_i = 1\}$  such that  $(w^*)^T x_j + b^* = 1$
- $\exists k \in \{i \in \{1, \dots, n\} | y_i = -1\}$  such that  $(w^*)^T x_k + b^* = -1$

# Hard margin SVC: Dual form

The SVC approach uses Lagrange multipliers for a simpler solution

$$L_H(w, b, \lambda) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \lambda_i (y_i (w^T x_i + b) - 1)$$

According to chapter 1, the dual problem should have a form of

$$\text{Dual SVC} \begin{cases} \text{Max} & g(\lambda) = \inf_{w \in \mathbb{R}^d, b \in \mathbb{R}} L_H(w, b, \lambda) \\ \text{s.t} & \lambda_i \geq 0 \quad i = 1, \dots, n \end{cases}$$

As  $L_H(w, b, \lambda)$  is strictly convex quadratic function of  $w$ , its minimal value is achieved at  $w$  satisfying  $\nabla_{w,b} L_H(w, b, \lambda) = 0$ , then

- $\nabla_w L_H(w, b, \lambda) = w - \sum_{i=1}^n \lambda_i y_i x_i = 0 \Rightarrow w = \sum_{i=1}^n \lambda_i y_i x_i$
- $\nabla_b L_H(w, b, \lambda) = \sum_{i=1}^n \lambda_i y_i = 0$

# Hard margin SVC: Dual form

- $L_H(w, b, \lambda) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \lambda_i (y_i (w^T x_i + b) - 1)$

- $w = \sum_{i=1}^n \lambda_i y_i x_i \Rightarrow$

$$L_H(w, b, \lambda) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_i y_j y_i (x_j^T x_i) - b \sum_{i=1}^n \lambda_i y_i$$

One has by substitution in  $L_H(w, b, \lambda)$  :

$$\inf_{w \in \mathbb{R}^d, b \in \mathbb{R}} L_H(w, b, \lambda) = \begin{cases} \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_i y_j y_i (x_j^T x_i) & \text{if } \sum_{i=1}^n \lambda_i y_i = 0 \\ -\infty & \text{if } \sum_{i=1}^n \lambda_i y_i \neq 0 \end{cases}$$

Optimisation non lineaire-Abdellatif El Afi

# Hard margin SVC: Dual form

$$D - SVC: \begin{cases} \text{Max} & g(\lambda) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_i y_j y_i (x_j^T x_i) \\ \text{s.t} & \sum_{i=1}^n \lambda_i y_i = 0 \\ & \lambda_i \geq 0 \quad i = 1, \dots, n \end{cases}$$

## Theorem:

For separable problems,


- The  $DC - SVC$  problem is a Convex Quadratic Programming and has a solution  $\lambda^*$
- For any solution  $\lambda^* = (\lambda_1^*, \dots, \lambda_n^*)$ , there must be a nonzero component  $\lambda_j^*$  and the unique solution to the primal  $SVC$  can be obtained in the following way

$$w^* = \sum_{i=1}^n \lambda_i^* y_i x_i \quad \text{and} \quad b^* = y_j - \sum_{i=1}^n \lambda_i^* y_i (x_j^T x_i)$$

# Hard margin SVC: Dual form

## Geometric interpretation

- Only the points closest to the separation surface affect its definition
- There are theoretical limits for the misclassification of new data
  - The larger the margin, the smaller the limit
  - The smaller the number of SVC, the smaller the limit



## Soft margin SVC( $C - SVC$ )

$$C - SVC \begin{cases} \text{Min} & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t} & y_i(w^T x_i + b) \geq 1 - \xi_i, i = 1, \dots, n \\ & \xi_i \geq 0, w \in \mathbb{R}^d, b \in \mathbb{R} \end{cases}$$

### Theorem:

- There exists solutions to the  $C - SVC$  problem w.r.t  $(w, b)$
- The solution  $w^*$  of the  $C - SVC$  problem (**with respect to**) w.r.t  $w$  is unique
- The solution set to the  $C - SVC$  problem w.r.t  $b$  is a bounded close interval  $[b_1, b_2]$  where  $b_1 \leq b_2$ .



## Soft-margin $C - SVC$ : Dual form

The C-SVC approach uses Lagrange multipliers for a simpler solution

$$\begin{aligned} L_{Soft}(w, \xi, b, \lambda, \mu) &= \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \lambda_i (y_i(w^T x_i + b) - 1 + \xi_i) - \sum_{i=1}^n \mu_i \xi_i \\ &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \lambda_i (y_i(w^T x_i + b) - 1) - \sum_{i=1}^n (-C + \lambda_i + \mu_i) \xi_i \end{aligned}$$

According to chapter 1, the dual problem should have a form of

$$Dual\ C - SVC \begin{cases} Max & g(\lambda, \mu) = \inf_{w \in \mathbb{R}^d, \xi \in \mathbb{R}^n, b \in \mathbb{R}} L_{Soft}(w, \xi, b, \lambda, \mu) \\ s.t & \lambda_i \geq 0, \mu_i \geq 0 \quad i = 1, \dots, n \end{cases}$$

As  $L_{Soft}(w, \xi, b, \lambda, \mu)$  is strictly convex quadratic function of  $w$ , its minimal value is achieved at  $w$  satisfying

$$\nabla_{w, \xi, b} L_{Soft}(w, \xi, b, \lambda, \mu) = 0$$

# Soft-margin $C - SVC$ : Dual form

Then

- $\nabla_w L_{Soft}(w, \xi, b, \lambda, \mu) = w - \sum_{i=1}^n \lambda_i y_i x_i = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n \lambda_i \mathbf{y}_i \mathbf{x}_i$
- $\nabla_{\xi} L_{Soft}(w, \xi, b, \lambda, \mu) = C I_{n \times n} - \lambda - \mu = 0$
- $\nabla_b L_{Soft}(w, \xi, b, \lambda, \mu) = \sum_{i=1}^n \lambda_i y_i = 0$

One has by substitution in  $L_{Soft}(w, \xi, b, \lambda, \mu)$ :

$$L_{Soft}(w, \xi, b, \lambda, \mu) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_i y_j y_i (x_j^T x_i) - b \sum_{i=1}^n \lambda_i y_i - \sum_{i=1}^n (-C + \lambda_i + \mu_i) \xi_i$$

If  $\sum_{i=1}^n \lambda_i y_i = 0$  and  $C I_{n \times n} - \lambda - \mu = 0$  then

- $\inf_{w \in \mathbb{R}^d, \xi \in \mathbb{R}^n, b \in \mathbb{R}} L_{Soft}(w, \xi, b, \lambda, \mu) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_i y_j y_i (x_j^T x_i)$

Else

- $\inf_{w \in \mathbb{R}^d, \xi \in \mathbb{R}^n, b \in \mathbb{R}} L_{Soft}(w, \xi, b, \lambda, \mu) = -\infty$

## Soft-margin $C - SVC$ : Dual form

$$Dual: C - SVC \left\{ \begin{array}{l} Max \quad g(\lambda, \mu) = g(\lambda) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_i y_j y_i (x_j^T x_i) \\ s.t \quad \sum_{i=1}^n \lambda_i y_i = 0 \\ C - \lambda_i - \mu_i = 0, i = 1, \dots, n \\ \mu_i \geq 0, \lambda_i \geq 0 \quad i = 1, \dots, n \end{array} \right.$$

- $\forall i = 1, \dots, n : C - \lambda_i - \mu_i = 0 \Leftrightarrow C - \lambda_i = \mu_i$
- $\mu_i \geq 0 \Leftrightarrow C - \lambda_i \geq 0 \Leftrightarrow C \geq \lambda_i$  and  $\lambda_i \geq 0 \Leftrightarrow C \geq \lambda_i \geq 0$

### Theorem:

- Dual  $C - SVC$  problem has a solution  $(\lambda^*, \mu^*)$
- Dual can be simplified to a problem only for a single variable  $\lambda$  by eliminating the variable  $\mu$  and then rewritten as a minimization problem  $Dual(C - SVC)_\lambda$

## Soft-margin $C - SVC$ : Dual $(C - SVC)_\lambda$ Form

$$Dual (C - SVC)_\lambda: \begin{cases} \text{Max} & L_{Soft}(\lambda) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_j \lambda_i y_j y_i (x_j^T x_i) \\ \text{s.t} & \sum_{i=1}^n \lambda_i y_i = 0 \\ & C \geq \lambda_i \geq 0 \quad i = 1, \dots, n \end{cases}$$

### Theorem:

- The  $Dual (C - SVC)_\lambda$  problem is a Convex Quadratic Programming and has a solution  $\lambda^*$
- For any solution  $\lambda^* = (\lambda_1^*, \dots, \lambda_n^*)$ , If there exists a component of  $\lambda^*$ ,  $\lambda_j^*$ , such that  $\lambda_j^* \in (0, C)$  then a solution  $(w^*, b^*)$  to the primal problem  $C - SVC$  w.r.t  $(w, b)$  can be obtained in by

$$w^* = \sum_{i=1}^n \lambda_i^* y_i x_i \quad \text{and} \quad b^* = y_j - \sum_{i=1}^n \lambda_i^* y_i (x_j^T x_i)$$